

Prototipo fachada

Seguro agrícola indexado para caficultores de Cauca y Nariño

Proyecto: Diseño de un seguro agrícola indexado basado en datos climáticos y satelitales

Curso: Proyecto Aplicado de Análítica de Datos - MIAD

Equipo: Daniel Santana, Martin Cufiño, José Gabriel Paredes y Monserrat Da Costa

Fecha: 12 de agosto de 2026

1. Definición preliminar del artefacto

AgroÍndice Café será un dashboard analítico demostrativo que integrará información climática y satelital de Cauca y Nariño. Permitirá comparar modelos candidatos, evaluar la capacidad de un índice climático para representar condiciones que afectan el cultivo de café y analizar posibles umbrales de activación del seguro.

El prototipo apoyará una decisión de avance hacia validación actuarial; no emitirá pólizas, no ejecutará indemnizaciones y no constituirá una plataforma comercial operativa.

2. Usuarios, beneficiarios y necesidad

El producto está dirigido a los equipos analíticos quienes interactuaran con el para comparar modelos candidatos y validar si el índice climático reduce el riesgo base a niveles aceptables. Un segundo usuario son los gerentes y directivos de la aseguradora, quienes requieren una vista resumida de las métricas de negocio para decidir si el modelo justifica avanzar hacia una siguiente fase.

Rol	Necesidad	Uso del prototipo
Usuario primario Analista de riesgo o datos	Comparar modelos, revisar calidad y validar umbrales.	Interactúa con las vistas analíticas y la trazabilidad.
Usuario secundario Gerente de producto o directivo	Decidir si los resultados justifican una siguiente fase.	Consulta la vista ejecutiva y las advertencias.
Stakeholders Caficultores, entidades financieras y reaseguradoras	Recibir un producto futuro más justo y confiable.	No interactúan directamente con el MVP.

3. Alcance del prototipo

MVP DEL CURSO	VERSIÓN FUTURA
Dashboard demostrativo para analistas y directivos.	Emisión de pólizas y ejecución real de indemnizaciones.

- Integración de datos climáticos y satelitales de Cauca y Nariño. - Comparación y validación de modelos candidatos. - Umbrales y activaciones históricas o simuladas. - Trazabilidad de fuentes, transformaciones y versión del modelo.	- Pricing actuarial completo e integración con sistemas corporativos. - Actualización automática y operación en producción. - Validación comercial de rentabilidad y retención. - Escalamiento nacional fuera de las zonas piloto.
---	---

Para la variable objetivo (Y) del modelo, se buscó primero el dato real de producción/rendimiento de café en Colombia, consultando las fuentes oficiales disponibles: el DANE (Encuesta Nacional Agropecuaria — ENA) y la Federación Nacional de Cafeteros (FNC). En ambos casos, el desglose por departamento (Cauca y Nariño) solo está disponible a nivel anual. Por esto, se tomó la decisión de usar NDVI y EVI (índices de vegetación satelitales) como variable proxy del estado del cultivo, lo cual permite trabajar a granularidad mensual en lugar de anual. Esto amplía el tamaño del dataset permitiendo obtener mejores resultados. Esta decisión está respaldada por la literatura, que documenta el uso de NDVI/EVI como proxy válido del estado del cultivo en el diseño de seguros indexados (Turvey & McLaurin, 2012; Mkhabela et al., 2005), aunque se reconoce como limitación que NDVI/EVI mide vigor vegetativo y no directamente el rendimiento en toneladas, por lo que la decisión será revisada en fases posteriores del proyecto si se logra acceder a datos de producción con mayor granularidad temporal.

Turvey, C. & McLaurin, M. (2012). Applicability of the Normalized Difference Vegetation Index (NDVI) in Index-Based Crop Insurance Design. *Weather, Climate, and Society*, 4(4). journals.ametsoc.org

4. Requerimientos del producto

A continuación se muestran los requerimientos del prototipo. Estos, de igual manera se encuentran en el entregable de "Tabla de Requerimientos"

Negocio

ID	Requerimiento	Prueba prevista	Criterio o métrica (rango deseado)
R1	Reducir el riesgo base del seguro indexado.	Backtesting: calcular $1 - r^2$ entre el índice climático y la variable de pérdida (o el proxy NDVI/EVI) en periodos históricos.	Riesgo base $\leq 50\%$
R2	Generar evidencia técnica que respalde la decisión de continuar invirtiendo en el desarrollo de un producto de seguro indexado para caficultores de Cauca y Nariño.	Comparación documentada de al menos 2 alternativas de modelo/índice climático frente a las métricas de desempeño ya definidas (R^2 , RMSE, Pearson).	Al menos 1 alternativa evaluada debe cumplir alguna de las metas mínimas de validación ($R^2 \geq 0.6$, Pearson ≥ 0.65 , RMSE $\leq 15\%$); si se cumple, se considera evidencia suficiente para recomendar avanzar a la siguiente fase.

Dado que no existen diversos cálculos de riesgo base en la literatura (algunos estudios lo miden como la diferencia directa entre el pago del índice y la pérdida real, otros mediante la correlación entre ambas variables), y dado que este proyecto no dispone de datos de pérdida monetaria real, se adopta como aproximación de riesgo base la relación $1 - r^2$ entre el índice climático y la variable de pérdida (o su proxy NDVI/EVI), un enfoque también utilizado, por ejemplo, por Jensen, Barrett y Mude (2016) al evaluar el seguro indexado de ganado en el norte de Kenia, donde reportan un R^2 de 0.13 a 0.38 entre el índice satelital y las pérdidas reales (riesgo base de 62%-87% incluso en ese producto ya consolidado). En nuestro propio draft, la correlación de Pearson obtenida entre el modelo climático y el NDVI/EVI ($r=0.62$) implica, bajo esta misma aproximación, un riesgo base actual de aproximadamente 62%. Se fija como meta un riesgo base $\leq 50\%$, una mejora exigente frente a esta línea base que no promete superar lo documentado para un producto ya validado en campo.

Referencias:

Jensen, N. D., Barrett, C. B., & Mude, A. G. (2016). Index Insurance Quality and Basis Risk: Evidence from Northern Kenya. *American Journal of Agricultural Economics*, https://ibli.ilri.org/wp-content/uploads/2015/01/jensen-barrett-mude-basis-risk-2014_12.pdf

Desempeño

ID	Requerimiento	Prueba prevista	Criterio o métrica (rango deseado)
R3	El modelo de regresión debe explicar razonablemente el comportamiento productivo o el nivel de afectación del cultivo.	Validación con separación temporal y por departamento (entrenamiento/prueba fuera de tiempo).	$R^2 \geq 0.60$
R4	El error de predicción del modelo de regresión debe ser acotado.	Cálculo de RMSE sobre el conjunto de prueba.	$RMSE \leq 15\%$ del valor medio de la variable objetivo.
R5	El índice climático seleccionado debe ser representativo del comportamiento del cultivo.	Cálculo de correlación entre el índice y la variable objetivo.	Correlación de Pearson ≥ 0.65
R6	El modelo debe ser estable entre periodos y departamentos.	Comparación de métricas de desempeño (R^2 , RMSE) por zona y por corte temporal.	Variación de métricas entre zonas o periodos documentada; degradación reportada explícitamente.

Para definir las metas de desempeño del modelo se combinó evidencia de la literatura con un ejercicio exploratorio propio. En estudios que predicen directamente el rendimiento o la producción de café a partir de variables climáticas y satelitales, los modelos de machine learning han alcanzado valores de R^2 de hasta 0.85 (Aprilia et al., 2025). Sin embargo, dado que este prototipo usa NDVI/EVI como variable proxy del rendimiento (ante la falta de granularidad temporal suficiente en los datos reales de

producción), existe una limitación adicional a considerar: en el único estudio identificado que predice específicamente NDVI a partir de variables climáticas en cultivos de café (Rojas-Briceño et al., 2024), el desempeño fue considerablemente menor, con un R^2 máximo de 0.15. Un primer draft de modelo desarrollado para este proyecto, con datos climáticos de NASA POWER y NDVI/EVI de MODIS (producto MOD13Q1) para Cauca y Nariño (2012-2019, n=190, validado una muestra de prueba), obtuvo un $R^2=0.35$, un RMSE equivalente al 9.7% de la media y un coeficiente de correlación de Pearson de 0.62, superando ya el techo reportado en la literatura específica de NDVI-clima para café. Con base en esta evidencia y nuestro ejercicio propio, se fijan las siguientes metas de desempeño para el prototipo final: $R^2 \geq 0.6$, RMSE $\leq 15\%$ de la media de la variable objetivo, y coeficiente de correlación de Pearson ≥ 0.65 . Estas metas son superiores frente al draft ya alcanzado, pero se mantienen conservadoras frente a los resultados positivos observados en la literatura, por las limitaciones antes mencionadas.

Referencias:

- Aprilia, A., Wahidin, A. B., & Abdurrahman, A. F. (2025). Integration of Machine Learning and NASA POWER Dataset for Predicting Coffee Production in Lampung: A Step Toward Smart Agriculture. *Jurnal Fisika Flux*, <https://ppjp.ulm.ac.id/journal/index.php/f/article/download/20980/11009>
- Rojas-Briceño, N. B. et al. (2024). Construction of Linear Models for the Normalized Vegetation Index (NDVI) for Coffee Crops in Peru Based on Historical Atmospheric Variables from the Climate Engine Platform. *Atmosphere*, <https://www.mdpi.com/2073-4433/15/8/923>

Funcional y de usabilidad

ID	Requerimiento	Prueba prevista	Criterio o métrica (rango deseado)
R7	El pipeline de datos debe ser trazable de principio a fin.	Revisión del registro de transformaciones aplicadas a los datos crudos.	100% de las transformaciones registradas.
R8	El tratamiento de datos faltantes debe ser transparente.	Inspección del reporte de imputación por variable.	% de registros imputados documentado para cada variable.
R9	El dashboard debe advertir explícitamente el alcance geográfico limitado.	Revisión visual: verificar que la nota de cobertura sea visible.	Nota de cobertura presente en el 100% de las vistas con resultados.
R10	Los supuestos, variables y umbrales usados deben quedar versionados.	Revisión de los metadatos de versión mostrados junto a cada resultado.	Versión o fecha visible junto a cada resultado mostrado.
R11	El dashboard debe servir tanto al analista como al directivo, cada uno con su propia vista.	Demo con un usuario de cada rol.	Ambos roles completan su tarea principal (comparar modelos / decidir avance) sin asistencia externa.
R12	La calidad de los datos utilizados debe ser aceptable.	Revisión de completitud tras la depuración.	$\geq 90\%$ de registros válidos.

R13	El prototipo debe construirse con herramientas de código abierto, sin licenciamiento comercial.	Revisión de las dependencias utilizadas.	Cumple (0 dependencias con licencia comercial).
------------	---	--	---

5. Preguntas analíticas que debe responder

ID	Pregunta analítica	Decisión soportada
P1	¿Qué variables climáticas y satelitales presentan mayor relación con la variable objetivo seleccionada?	Selección de variables e interpretación del índice.
P2	¿Cuál modelo candidato ofrece el mejor desempeño para estimar el comportamiento productivo o nivel de afectación?	Seleccionar o descartar alternativas.
P3	¿Con qué precisión pueden identificarse condiciones climáticas críticas asociadas con una posible activación?	Evaluar la confiabilidad del trigger.
P4	¿Qué umbrales representan mejor las condiciones de Cauca y Nariño?	Calibrar reglas regionales de activación.
P5	¿Qué tan estable es el modelo entre periodos y departamentos, y qué limitaciones introduce la calidad de los datos?	Definir monitoreo, recalibración y límites de uso.

6. Métricas clave de negocio y de seguimiento del proyecto

Estas métricas, heredadas del anteproyecto de Gerencia de Proyectos de Analytics, permiten valorar si el artefacto agrega valor real al negocio y si el proyecto avanza según lo planeado. Las metas de desempeño técnico del modelo (R^2 , RMSE y correlación de Pearson) se codifican aquí como D1-D3 para mantener trazabilidad con la matriz de la sección 11.

Métricas de negocio

Código	Métrica	Valor actual	Meta
N1	Riesgo base	25%	≤50%

Métricas de desempeño del modelo (referencia)

Código	Métrica	Meta
D1	R^2 (regresión)	≥0.6
D2	RMSE (regresión)	≤15% del valor medio
D3	Correlación de Pearson (índice)	≥0.6

Métricas de seguimiento del proyecto

- Calidad de datos: más del 95% de registros válidos.
- Cumplimiento del cronograma planeado para esta fase del curso.

7. Tipos de análisis y modelos

El bloque de análisis del diagrama de la sección 8 involucra tres tipos de análisis, cada uno alimentando una decisión de negocio distinta.

Análisis descriptivo

Busca entender la relación entre las variables climáticas y satelitales y su comportamiento histórico, mediante gráficos descriptivos, distribuciones y coeficientes de correlación. Alimenta directamente la pregunta P1 de la sección 5.

Análisis predictivo


Se apoya en dos familias de modelos candidatos (Random Forest, XGBoost, SVM y redes neuronales) que responden preguntas de negocio distintas. La regresión estima el comportamiento productivo o el nivel de afectación esperado del cultivo, y alimenta el cálculo de pérdidas esperadas (preguntas P1-P2).

8. Prototipo Fachada

Ruta preliminar desde las fuentes hasta la decisión del usuario.

USUARIO Y NECESIDAD

- **Usuario primario (analista de riesgo o datos):** comparar modelos, revisar calidad y validar umbrales.
- **Usuario secundario (gerente de producto o directivo):** decidir si los resultados justifican avanzar a una siguiente fase.
- **Necesidad común:** reducir el riesgo base del índice climático que sustentaría el seguro agrícola indexado para caficultores de Cauca y Nariño.



ENTRADA ANALÍTICA	SALIDA DEL MODELO	DECISIÓN SOPORTADA
Variables climáticas, satelitales y variable objetivo seleccionada.	Predicción, métricas, umbral y nivel de incertidumbre.	Continuar, recalibrar o descartar la alternativa antes de una validación actuarial.

MÉTRICAS DE VALIDACIÓN

- **Negocio (N1-N):** riesgo base $\leq 50\%$,
- **Desempeño del modelo (D1-D4):** $R^2 \geq 0.6$, $RMSE \leq 15\%$, correlación de Pearson ≥ 0.65 .
- **Uso en la decisión:** estas métricas son las que determinan si el bloque de Resultados respalda continuar, recalibrar o descartar la alternativa antes de la validación actuarial.

Notas de diseño del flujo

- La extracción se apoyará principalmente en Google Earth Engine y conservará filtros de zona, periodo y fuente.
- La transformación debe evitar reemplazar silenciosamente valores faltantes por cero y registrar toda imputación.
- Los modelos candidatos son alternativas a comparar; el prototipo no presupone cuál será el ganador.
- La salida final debe incluir métricas, versión, alcance geográfico e incertidumbre o limitaciones.

9. Qué hace el artefacto y forma de uso

El artefacto se entrega como un tablero de visualización y control (dashboard) que organiza la información en capas, de resumen a detalle, para que cada usuario acceda solo al nivel de profundidad que necesita. Se propone dividirlo en tres vistas:

- **Vista de resumen ejecutivo:** dirigida a gerencia de producto; agrupa los KPIs de negocio y de calidad de datos y las advertencias de interpretación (Pantalla 1).
- **Vista de validación analítica:** dirigida al equipo analítico; compara los modelos candidatos, sus métricas y las variables más relevantes (Pantalla 2).
- **Vista de índice y activaciones:** dirigida al equipo analítico y de auditoría; muestra la regla de activación, los umbrales por zona y el historial de activaciones (Pantalla 3).

Estas tres vistas se detallan como mockup en la sección 10 y su soporte de back-end se verifica en la matriz de trazabilidad de la sección 11.

10. Mockup del front-end – Pantalla 1

Pantalla 1. Vista ejecutiva para decidir si el modelo debe avanzar a una siguiente fase.

AgroÍndice Café

Pantalla 1 - Resumen ejecutivo

Gerencia de producto

1 Resumen ejecutivo

2 Validación analítica

3 Índice y activaciones

Departamento Cauca y Nariño

Periodo Por definir

Modelo Recomendado

Versión v0.1

RIESGO BASE / PROXY

Meta del proyecto: ≤10%

MODELO RECOMENDADO

Pendiente de validación

CALIDAD DE DATOS

Meta: ≥90% válidos

ALCANCE

2 zonas

Cauca y Nariño

Desempeño y utilidad del artefacto

Comparación entre escenario base y modelo seleccionado

Escenario base

Modelo candidato

Meta

Marcador visual - se reemplazará con resultados reales.

Estado: pendiente de resultados.

Continuar si el modelo cumple las métricas mínimas.

Recalibrar si existe degradación temporal o regional.


No interpretar rentabilidad o retención como resultados observados.

Advertencia de interpretación: si no se obtiene información de pérdida o rendimiento real, esta pantalla mostrará una métrica proxy de cobertura basada en NDVI/EVI, no una reducción comprobada del riesgo base.

Página 9 | Proyecto Aplicado de Analítica de Datos

10. Mockup del front-end – Pantalla 2

Pantalla 2. Vista analítica para comparar modelos, revisar errores y entender variables relevantes.



10. Mockup del front-end – Pantalla 3

Pantalla 3. Vista de reglas, umbrales y activaciones históricas o simuladas.

AgroÍndice Café

Pantalla 3 - Índice y activaciones

Analista / auditor

1 Resumen ejecutivo

2 Validación analítica

3 Índice y activaciones

Departamento Nariño

Periodo Histórico

Evento Todos

Versión v0.1

ÍNDICE CLIMÁTICO

Valor por periodo

UMBRAL

Calibrado por zona

ACTIVACIONES

Históricas/simuladas

MODELO

v0.1

Fecha y trazabilidad

REGLA DE ACTIVACIÓN - BORRADOR

SI índice climático < umbral regional
ENTONCES marcar evento potencial
Y estimar pago teórico / nivel de afectación

La regla definitiva dependerá de la variable objetivo, la ventana temporal y el modelo seleccionado.

Historial de activaciones

Periodo	Zona	Índice	Umbral	Estado
AAAA-MM	Nariño	—	—	Por calcular
AAAA-MM	Nariño	—	—	Por calcular
AAAA-MM	Nariño	—	—	Por calcular
AAAA-MM	Nariño	—	—	Por calcular

COBERTURA GEOGRÁFICA

Resultados limitados a Cauca y Nariño.

CALIDAD DE DATOS

Mostrar porcentaje imputado y fuentes utilizadas.

TRAZABILIDAD

Mostrar fecha, versión, variables y umbrales.

11. Trazabilidad entre front-end y back-end

La siguiente matriz evita que el mockup prometa información que el flujo analítico no puede producir.

Pantalla	Necesidad del usuario	Componente de back-end	Salida visible	Req. relacionado
1	Decidir si el modelo justifica una siguiente fase.	Validación, métricas de negocio y calidad de datos.	KPIs, estado general y advertencias.	R1-R2, R11, R12
2	Comparar modelos y entender su estabilidad.	Regresión, validación temporal e interpretabilidad.	Tabla comparativa, errores y variables relevantes.	R3-R6, R9
3	Comprender cuándo se activa el índice y por qué.	Cálculo del índice, umbral regional, backtesting y versionado.	Regla, historial de activaciones y trazabilidad.	R5, R7, R8, R10